Script: Recunoașterea automată a vorbirii

De citit în timpul înregistrării, câte un bloc pe slide (~5 min în total, cu pauze între slide-uri). Același text e și în notele fiecărui slide (Presenter View).

SLIDE 1 · RECUNOAȘTEREA AUTOMATĂ A VORBIRII (TITLU) ~35 s

Bună ziua. Mă numesc Traian File-Mitiță, sunt în grupa 441A, și în prezentarea de astăzi o să vorbesc despre recunoașterea automată a vorbirii, adică despre felul în care un calculator transformă vocea noastră în text. Am ales tema asta pentru că pornește exact de la ce am făcut la laboratoare – spectrul, spectrograma, formanții – și arată cum s-a ajuns de la acești parametri la sistemele pe care le folosim zilnic, cum sunt asistenții vocali sau subtitrările automate.

SLIDE 2 · INTERFEȚELE VOCALE SUNT PESTE TOT ~39 s

Interfețele vocale sunt peste tot: asistenții de pe telefon, dictarea, comenzile din mașină și, foarte important, aplicațiile de accesibilitate pentru persoanele cu deficiențe de vedere sau de mobilitate. Un asistent vocal funcționează ca un lanț. Mai întâi, un model foarte mic ascultă doar cuvântul de activare, de exemplu „Hey Siri”. Apoi recunoașterea vorbirii transformă ce spunem în text, modulul de înțelegere a limbajului află ce vrem, adică intenția, iar la final sinteza vocală ne răspunde. În prezentare mă concentrez pe a doua verigă: recunoașterea vorbirii.

SLIDE 3 · DE LA SEMNAL LA PARAMETRI ~49 s

Totul pornește de la semnal. Pentru că vorbirea se schimbă de la un fonem la altul, semnalul se împarte în cadre de 20–30 de milisecunde, peste care se aplică o fereastră Hamming. Pe fiecare cadru putem calcula parametrii de timp scurt de la laborator: energia, rata de treceri prin zero și frecvența fundamentală. În domeniul frecvență apar formanții. Aici este spectrograma cuvântului „casă”, înregistrat de mine: pentru vocala „a” am obținut primul formant pe la 790 de herți și al doilea pe la 1290. Sistemele de recunoaștere folosesc de obicei coeficienții MFCC, care descriu compact tot spectrul, pe scara Mel, apropiată de felul în care aude urechea umană.

SLIDE 4 · RECUNOAȘTEREA CLASICĂ (1980–2010) ~43 s

Primele sisteme comparau cuvântul rostit cu niște șabloane înregistrate dinainte, folosind alinierea dinamică în timp, care compensează faptul că nu vorbim niciodată exact la fel de repede. Asta mergea pentru câteva zeci de comenzi, dar nu și pentru vorbire continuă. Între anii '80 și 2010, standardul au fost modelele Markov ascunse. Fiecare fonem are un model cu trei stări, iar sistemul complet are trei părți: modelul acustic, dicționarul de pronunție și modelul de limbă, care știe ce succesiuni de cuvinte sunt probabile. Algoritmul Viterbi caută apoi propoziția care se potrivește cel mai bine cu semnalul.

SLIDE 5 · RECUNOAȘTEREA CU REȚELE NEURONALE ~49 s

Pe la 2012, rețelele neuronale profunde au înlocuit o parte din modelul acustic și au redus erorile cu aproximativ o treime. Apoi au apărut sistemele end-to-end, în care o singură rețea învață direct de la semnal la text. Un exemplu actual este Whisper, de la OpenAI, antrenat pe aproximativ 680.000 de ore de audio în aproape 100 de limbi, inclusiv româna. Ce mi s-a părut interesant este că la intrarea lui se află tot o spectrogramă Mel, deci noțiunile de la curs sunt în continuare baza. Calitatea se măsoară prin rata de eroare pe cuvinte, WER: cuvintele înlocuite, șterse și inserate, împărțite la numărul total de cuvinte.

SLIDE 6 · PROVOCĂRI ȘI CONCLUZII ~41 s

Chiar dacă recunoașterea este acum foarte bună, mai sunt probleme: zgomotul din mediu, accentele și vorbirea spontană, faptul că pentru limba română sunt mult mai puține date decât pentru engleză, confidențialitatea, pentru că multe sisteme trimit vocea în cloud, și întârzierea, pentru că un dialog natural cere un răspuns în mai puțin de o secundă. Ca o concluzie: am trecut de la șabloane pentru câteva cuvinte la rețele antrenate pe sute de mii de ore, dar baza a rămas aceeași – cadre, spectru, spectrogramă și formanți. Vă mulțumesc pentru atenție!